

Rapport de Projet Machine Learning

Ce rapport décrit les différentes étapes suivies pour la réalisation d'un projet de Machine Learning visant à prédire le statut d'une demande de prêt.

1. Introduction

L'objectif du projet est de développer un modèle capable de prédire la variable cible « Status » à partir des caractéristiques des clients et des informations relatives aux prêts.

2. Présentation du jeu de données

Le jeu de données contient des informations sur les demandes de prêts. La variable cible est « Status ». Les autres variables représentent les caractéristiques utilisées pour effectuer la prédiction.

3. Exploration des données (EDA)

Une analyse exploratoire des données a été réalisée afin de comprendre la structure du dataset. Les opérations effectuées incluent :

- Affichage des premières lignes du dataset ;
- Vérification des dimensions ;
- Analyse des types des variables ;
- Recherche des valeurs manquantes ;
- Recherche des doublons ;
- Analyse descriptive des variables numériques ;
- Étude de la distribution de la variable cible ;
- Visualisation des corrélations.

4. Prétraitement des données

Les données ont été préparées avant l'entraînement des modèles :

- Suppression des variables inutiles ;
- Traitement des valeurs manquantes ;
- Encodage des variables catégorielles ;
- Séparation des variables explicatives (X) et de la variable cible (y).

5. Division des données

Le dataset a été divisé en deux ensembles : un ensemble d'entraînement (80 %) et un ensemble de test (20 %).

6. Entraînement des modèles

Plusieurs algorithmes de classification ont été testés afin d'identifier le modèle le plus performant.

- Logistic Regression
- Decision Tree
- Random Forest
- K-Nearest Neighbors (KNN)
- Naïve Bayes
- Support Vector Machine (SVM)

7. Évaluation des performances

Les modèles ont été évalués à l'aide de différentes métriques de performance.

- Accuracy
- Precision
- Recall
- F1-score
- Matrice de confusion

8. Choix du modèle final

Après comparaison des résultats, le modèle retenu est : `best_model_random_forest`.

9. Sérialisation du modèle

Le modèle final a été sauvegardé afin de pouvoir être réutilisé ultérieurement sans nécessiter un nouvel entraînement.

10. Déploiement

Une application Streamlit a été développée pour permettre à l'utilisateur d'effectuer des prédictions à partir de nouvelles données.

11. Conclusion

Ce projet a permis d'appliquer les différentes étapes d'un processus complet de Machine Learning, depuis l'exploration des données jusqu'au déploiement du modèle final.